Personal Project — AI in Medical Applications

Approaches towards Radiologist-Centered AI Agent

Per-Reader Adaptation · Learning to Defer · Human–AI Evaluation

Prototype Design

Nguyễn Duy Khải

Tóm tắt. Báo cáo phân tích ba hướng nghiên cứu cốt lõi trong repository `Radiologist-Centered-AI-Agent` và đối chiếu chúng với các câu hỏi nghiên cứu Q1–Q4 của AIMA Project II. Ba hướng không phải ba module độc lập mà tạo thành một vòng lặp: per-reader adaptation học cách một bác sĩ dùng lời khuyên của AI; learning to defer dùng mô hình hành vi đó để quyết định khi nào AI nên hiển thị gợi ý và khi nào nên nhường cho bác sĩ đọc độc lập; human–AI evaluation kiểm tra trong một thí nghiệm có đối chứng xem cá nhân hóa và deferral có thực sự cải thiện quyết định cuối cùng của con người hay không. Với mỗi hướng, báo cáo trình bày khái niệm, mô hình toán học (hồi quy logistic MAP, làm trơn bằng prior Beta, entropy dự đoán, tối thiểu hóa mất mát kỳ vọng, common random numbers), đoạn mã tương ứng, cùng các giới hạn cần lưu ý trước khi dùng kết quả để viết bài báo.

Mục lục

1 Giới thiệu **2**

1.1 Bối cảnh và câu hỏi nghiên cứu 2

1.2 Ba hướng tạo thành một vòng lặp 3

2 Kiến trúc hệ thống và ký hiệu **3**

2.1 Pipeline first-read 3

2.2 Ký hiệu 4

3 Nền tảng chung: hiệu chỉnh xác suất và độ bất định **4**

3.1 Hiệu chỉnh xác suất (Calibration) 4

4 Hướng 1 — Per-Reader Adaptation **8**

4.1 Động cơ 9

4.2 Thu thập phản hồi theo giao thức đọc tuần tự 9

4.3 Mô hình Trust Curve và ước lượng logistic MAP 10

4.4 Ước lượng tỉ lệ lapse 12

4.5 Từ mô hình hành vi đến chính sách cá nhân hóa 12

5 Hướng 2 — Learning to Defer **12**

5.1 Khác gì so với đặt ngưỡng độ tin thông thường? 12

5.2 Quy tắc quyết định: AI làm gì với từng ca? 13

5.3 Tối ưu ngưỡng cá nhân hóa bằng mất mát kỳ vọng 15

6 Hướng 3 — Human–AI Evaluation **18**

6.1 Bác sĩ mô phỏng 18

6.2 Các chính sách được so sánh 20

6.3 Các chỉ số đánh giá 20

6.4 Ý nghĩa và giới hạn của kết quả mô phỏng 21

1 Giới thiệu

1.1 Bối cảnh và câu hỏi nghiên cứu

Một bác sĩ chẩn đoán hình ảnh làm việc với một *worklist*, tức hàng đợi các ca chụp CT/MRI chờ đọc. Phần lớn ca là bình thường, một số ít là khẩn cấp, nhưng ca nào cũng cần đo đạc cẩn thận và một báo cáo viết. AI hình ảnh hiện nay đã phát hiện và phân đoạn được nhiều tổn thương, nhưng khi triển khai nó hành xử *giống nhau với mọi bác sĩ* và không học từ các chỉnh sửa của họ.

Các bằng chứng mà Project II dựa vào cho thấy vì sao cách làm đó chưa đủ:

- **Lợi ích không đồng đều.** Trên 140 bác sĩ và 15 tác vụ X-quang ngực, tác động của cùng một trợ lý AI thay đổi rất mạnh giữa các bác sĩ. Kinh nghiệm, chuyên khoa hay việc từng dùng AI đều không dự báo được ai hưởng lợi, và các dự đoán sai của AI làm bác sĩ kém đi [1].
- **Automation bias.** Khi gợi ý BI-RADS của AI sai, độ chính xác của bác sĩ nhũ ảnh ở mọi cấp kinh nghiệm đều giảm; với người ít kinh nghiệm, độ chính xác tụt từ 79.7% xuống 19.8% [3].
- **Định tuyến tốt hơn hỗ trợ đồng loạt.** Bác sĩ đánh giá thấp lời khuyên của AI và coi nó như độc lập với nhận định của mình; chuyển từng ca cho người *hoặc* AI có thể tốt hơn [2]. CoDoC học khi nào nên tin AI và khi nào nên nhường cho bác sĩ, giảm 25% dương tính giả và 66% khối lượng công việc trong sàng lọc ung thư vú tại Anh [5].

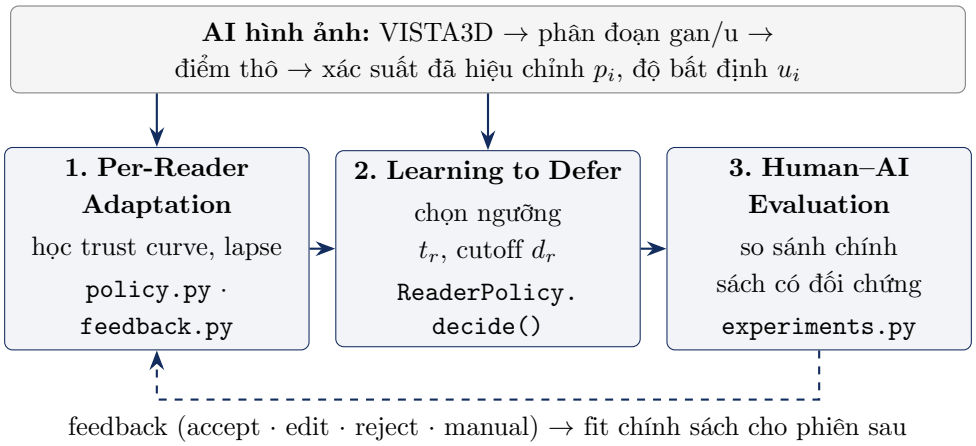
Từ đó Project II đặt câu hỏi trung tâm: *Một trợ lý AI có thể thích ứng với từng bác sĩ, thay vì hỗ trợ mọi người như nhau, và biết khi nào nên lùi lại hay không?* Bốn câu hỏi con được đặt ra:

Q1	Thích ứng theo từng bác sĩ có giảm biến thiên lợi ích giữa các bác sĩ mà Yu et al. báo cáo không?
Q2	Learning to defer có giảm tác hại của gợi ý AI sai, đo trên các ca AI sai, không?
Q3	Hệ thống cần bao nhiêu lần chỉnh sửa trước khi giúp được một bác sĩ mới, và hành vi của nó có ổn định không?
Q4	Bác sĩ mô phỏng có dự báo đúng cách bác sĩ thật phản ứng trong pilot không?

Bảng 1: Bốn câu hỏi nghiên cứu từ Project II.

1.2 Ba hướng tạo thành một vòng lặp

Điểm quan trọng nhất để hiểu repository là ba hướng nghiên cứu **không phải ba module AI độc lập**. Chúng nối với nhau như trong Hình 1:



Hình 1: Vòng lặp nghiên cứu. Trong thí nghiệm, việc fit chính sách (trên tập calib) và đánh giá (trên tập test) được tách biệt; feedback từ tập test không được đưa ngược vào để fit chính sách trong cùng thí nghiệm.

Bản chất của quá trình học

Repository **không huấn luyện lại trọng số của VISTA3D**. Thứ được học là các tham số của quyết định: trust curve và tỉ lệ lapse của từng bác sĩ (mô hình hành vi), ngưỡng gợi ý t_r và ngưỡng hoãn d_r (chính sách). Đây là policy-level adaptation, không phải fine-tuning một foundation model cho từng bác sĩ.

2 Kiến trúc hệ thống và ký hiệu

2.1 Pipeline first-read

Agent trong `radagent/agent/` chạy một chuỗi công cụ có thứ tự và điều kiện tiên quyết:

`load_study` ⟶ `segment_liver_tumour` ⟶ `measure_findings` ⟶ `quality_check`

↓

`estimate_confidence` ⟶ `triage_case` ⟶ `apply_reader_policy` ⟶ `draft_report`

Planner mặc định là luật cố định; một LLM mở (mặc định `qwen2.5:7b-instruct`) có thể đề xuất bước tiếp theo, nhưng chỉ nhận mô tả công cụ và bản tóm tắt, không nhận pixel CT, và mọi đề xuất sai thứ tự sẽ quay về planner luật. Dữ liệu là LiTS17 gồm 131 ca CT [9], chia ngẫu nhiên có seed thành khoảng 65 ca *calib* và 66 ca *test*; không có tập train vì không có mô hình nào được huấn luyện. Mô hình phân đoạn là VISTA3D [8].

Mỗi ca được xếp vào worklist theo một điểm ưu tiên minh bạch

$$\text{priority}_i = 0.60\, p_i + 0.25\, \frac{\log(1+V_i)}{\log(1+50)} + 0.15\, u_i, \tag{1}$$

với V_i là thể tích u dự đoán (ml). Hệ thống đồng thời gán một nhãn triage thuộc các nhóm: `QC FAIL`, `URGENT`, `SUSPICIOUS`, `UNCERTAIN` hoặc `LIKELY NORMAL`. Đây là các quy tắc nghiên cứu, không phải quyết định lâm sàng đã được kiểm chứng.

2.2 Ký hiệu

Ký hiệu	Ý nghĩa
i, r	một ca CT; một bác sĩ (reader)
$p_i \in [0,1]$	xác suất ca có u, đã hiệu chỉnh
$u_i \in [0,1]$	độ bất định của AI (entropy, đơn vị bit)
$g_i \in \{0,1\}$	nhãn tham chiếu từ mask LiTS (không phải kết luận của AI hay của bác sĩ)
$o_{ir} \in \{0,1\}$	nhận định *ban đầu, độc lập* của bác sĩ r
$a_i \in \{0,1\}$	nhãn AI gợi ý; c_i là độ tin của AI vào nhãn đó
$f_{ir} \in \{0,1\}$	quyết định cuối cùng của bác sĩ
t_r, d_r	ngưỡng gợi ý và ngưỡng hoãn (deferral cutoff) của bác sĩ r
$D_i \in \{0,1\}$	$D_i = 1$ nghĩa là hoãn: không hiển thị gợi ý AI

Bảng 2: Ký hiệu dùng trong toàn báo cáo.

3 Nền tảng chung: hiệu chỉnh xác suất và độ bất định

Cả ba hướng đều dựa trên hai đại lượng cho mỗi ca, p_i và u_i. Nếu hai đại lượng này sai, mọi quyết định phía sau đều sai, nên chúng cần được hiểu trước.

3.1 Hiệu chỉnh xác suất (Calibration)

Định nghĩa: Mô hình được hiệu chỉnh

Một mô hình được hiệu chỉnh (calibrated) khi độ tin của nó khớp với tần suất đúng: trong tất cả các ca nó báo xác suất 0.8, khoảng 80% thực sự có u. Hình thức hóa: $\Pr(g = 1 \mid p = s) = s$ với mọi s.

3.1.1 Điểm thô của VISTA3D

VISTA3D gán cho từng voxel (một điểm ảnh 3D, mỗi cạnh khoảng 1.5 mm) một số từ 0 đến 1 cho biết vị trí đó "giống mô u" đến mức nào. Bài toán của repo lại cần một con số

cho cả ca: "ca này có u không?". Hàm `inference.py` gộp bản đồ voxel thành một điểm qua ba bước tuần tự:

Bước 1. Vùng gan đã giãn. Lấy mask gan do mô hình dự đoán rồi nở thêm một lớp voxel ra mọi phía (morphological dilation), để không bỏ sót u nằm sát rìa gan.

Bước 2. Làm mượt. Lấy trung bình cục bộ trên từng lát cắt, để một voxel nhiễu đơn lẻ không tạo ra điểm cao giả.

Bước 3. Top-k. Lấy trung bình của k voxel có giá trị cao nhất trong vùng đó, với k tương ứng khoảng 0.1 ml, cỡ một tổn thương rất nhỏ. Ca có ít nhất một ổ nhỏ "rất giống u" sẽ có điểm cao.

Kết quả là điểm thô p_i^{raw}. Nó xếp hạng được ca nào giống có u hơn, nhưng con số 0.9 chưa chắc có nghĩa là 90% các ca như vậy có u, cũng như điểm thi 9/10 không có nghĩa là xác suất đỗ là 90%. Các mạng neural hiện đại thường quá tự tin [10], nên cần một bước hiệu chỉnh (calibration): học một hàm đổi điểm thô thành xác suất.

3.1.2 Logit và sigmoid: hai phép đổi thang đo

Logit và Sigmoid

Logit đổi một xác suất $p \in (0, 1)$ thành "log của tỉ số cược" trên toàn trục số thực:

$$\text{logit}(p) = \ln \frac{p}{1-p} \in (-\infty, +\infty).$$

Sigmoid là hàm ngược, đưa một số thực bất kỳ về lại khoảng $(0, 1)$: $\sigma(z) = 1/(1 + e^{-z})$, và $\sigma(\text{logit}(p)) = p$.

p	0.01	0.10	0.50	0.90	0.99
$z = \text{logit}(p)$	-4.60	-2.20	0	2.20	4.60

Ở thang logit ta có thể nhân hoặc cộng thoải mái (co giãn, dịch chuyển), rồi đưa qua sigmoid thì kết quả *luôn* là một xác suất hợp lệ trong $(0, 1)$. Ta ký hiệu $z_i = \text{logit}(p_i^{\text{raw}})$.

3.1.3 Ba phương pháp hiệu chỉnh được so sánh

$$\text{identity:} \quad p_i = p_i^{\text{raw}}, \tag{2}$$

$$\text{temperature scaling [10]:} \quad p_i = \sigma(z_i/T), \tag{3}$$

$$\text{Platt scaling [11]:} \quad p_i = \sigma(a z_i + b). \tag{4}$$

- **Identity** giữ nguyên điểm thô. Đây là mốc so sánh "không làm gì": nếu nó thắng, điểm thô vốn đã đủ tốt.

- **Temperature scaling** chia logit cho một số $T > 0$ (gọi là "nhiệt độ"). $T > 1$ kéo mọi xác suất về gần 0.5, làm mô hình bớt tự tin; $T < 1$ đẩy chúng ra xa 0.5. Ví dụ với $T = 2$, điểm thô 0.9 có $z = 2.20$, nên $p = \sigma(1.10) = 0.75$.
- **Platt scaling** dùng hai tham số: độ dốc a (vai trò giống 1/T) và độ lệch b. Độ lệch b sửa được trường hợp mô hình nghiêng hẳn về một phía, ví dụ luôn đánh giá khả năng có u quá cao. Ví dụ với $a = 0.8$, $b = -0.5$: $p = \sigma(0.8 \cdot 2.20 - 0.5) = \sigma(1.26) \approx 0.78$.

Cả ba hàm đều đồng biến: ca nào có điểm thô cao hơn thì vẫn có xác suất cao hơn. Hiệu chỉnh chỉ sửa ý nghĩa của con số, không đổi thứ tự các ca. Hệ quả là AUROC (xem dưới) không thay đổi sau hiệu chỉnh.

3.1.4 Tìm tham số: negative log-likelihood

T, a, b được chọn sao cho xác suất khớp nhất với nhãn thật g_i trên tập calib, bằng cách tối thiểu hóa **negative log-likelihood** (NLL):

$$\text{NLL} = -\frac{1}{N}\sum_i \big[g_i \log p_i + (1 - g_i)\log(1 - p_i)\big]. \tag{5}$$

Cách đọc: với mỗi ca, lấy xác suất mà mô hình gán cho *đáp án đúng* (là p_i nếu có u, $1 - p_i$ nếu không có u), lấy $-\log$, rồi tính trung bình. Mô hình càng gán xác suất cao cho đáp án đúng thì NLL càng nhỏ.

Tình huống	Đúng và tự tin	Đúng nhưng do dự	Sai và tự tin
$(g_i,\ p_i)$	$(1,\ 0.9)$	$(1,\ 0.6)$	$(0,\ 0.9)$
Phạt NLL $= -\log$(xác suất cho đáp án đúng)	0.105	0.511	**2.303**
Phạt Brier $= (p_i - g_i)^2$	0.01	0.16	**0.81**

Tự tin mà sai bị phạt rất nặng, nên mô hình không bao giờ có lợi khi báo "99%" nếu thực tế chỉ đúng 80%. Trong code, T được tìm bằng tìm kiếm một chiều có chặn trên $\log T$, còn (a, b) bằng thuật toán tối ưu L-BFGS-B.

Điều chuẩn Ridge

Với Platt, repo cộng thêm vào NLL một khoản phạt nhỏ $10^{-3}\big[(a-1)^2 + b^2\big]$, tăng dần khi (a, b) rời xa $(1, 0)$, tức rời xa trạng thái "không thay đổi gì". Tập calib chỉ có khoảng 65 ca, nên không có khoản phạt này thì vài ca bất thường có thể đẩy a, b tới giá trị cực đoan.

3.1.5 Lựa chọn phương pháp bằng cross-validation phân tầng

Quy trình cross-validation

Ở chế độ `auto`, repo:

Bước 1. Chia tập calib thành k phần (mặc định $k = 5$; giảm xuống khi có ít ca thuộc một lớp);

Bước 2. Lần lượt giữ lại một phần, fit từng phương pháp trên $k-1$ phần còn lại, rồi đo NLL trên phần bị giữ lại. Mỗi ca được "thi" đúng một lần bởi một mô hình chưa từng thấy nó;

Bước 3. Lấy trung bình NLL qua k lượt, chọn phương pháp có NLL thấp nhất, rồi fit lại phương pháp đó trên *toàn bộ* tập calib.

Phân tầng (stratified): mỗi phần giữ cùng tỉ lệ ca có u và không u như cả tập. Điều này quan trọng với LiTS vì đa số ca có u: chia ngẫu nhiên thuần túy có thể tạo ra một phần không có ca âm tính nào. Nhờ cross-validation, phương pháp nhiều tham số hơn (Platt) không tự động thắng: nếu nó chỉ học thuộc nhiễu, NLL trên phần bị giữ lại sẽ tệ hơn.

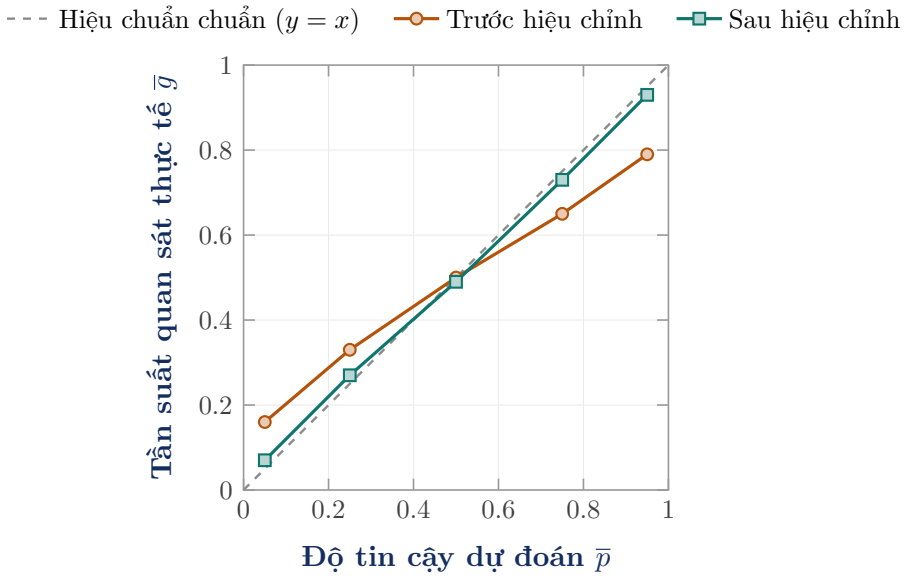
3.1.6 Các chỉ số đánh giá hiệu chỉnh

Brier score

Brier score là trung bình bình phương sai lệch giữa xác suất dự đoán và nhãn tham chiếu:

$$\text{Brier} = \frac{1}{N}\sum_{i}(p_i - g_i)^2. \tag{6}$$

Brier bằng 0 là hoàn hảo; luôn báo 0.5 cho mọi ca thì được 0.25. Brier phạt nhẹ hơn NLL khi tự tin mà sai (tối đa bằng 1, xem bảng trên).



Hình 2: Reliability diagram minh họa chất lượng hiệu chuẩn xác suất trước và sau khi tối ưu.

Reliability diagram và ECE

Chia khoảng $[0, 1]$ thành $B = 10$ *bin* (ngăn), ví dụ $[0, 0.1)$, $[0.1, 0.2)$, ... Mỗi ca rơi vào một bin theo p_i. Gọi S_b là tập các ca trong bin b. Trong mỗi bin, so sánh hai con số:

độ tin trung bình $\overline{p}_{S_b}$ (AI nói trung bình bao nhiêu) và *tần suất thật* $\overline{g}_{S_b}$ (tỉ lệ ca trong bin thực sự có u). Vẽ $\overline{g}_{S_b}$ theo $\overline{p}_{S_b}$ ta được **reliability diagram** (Hình 2). Mô hình hiệu chỉnh tốt có các điểm nằm trên đường chéo. **Expected calibration error** là khoảng cách trung bình tới đường chéo, có trọng số theo số ca trong bin:

$$\mathrm{ECE} = \sum_{b=1}^{B} \frac{|S_b|}{N} \left| \overline{g}_{S_b} - \overline{p}_{S_b} \right|. \tag{7}$$

Ví dụ với $N = 30$ ca: một bin có 10 ca, AI báo trung bình 0.85 nhưng chỉ 6 ca có u (tần suất 0.60, lệch 0.25); một bin khác có 20 ca, AI báo trung bình 0.15 và 2 ca có u (tần suất 0.10, lệch 0.05). Khi đó ECE $= \frac{10}{30} \cdot 0.25 + \frac{20}{30} \cdot 0.05 \approx 0.117$: trung bình AI lệch khoảng 12 điểm phần trăm so với thực tế.

Repo tính ECE theo hai cách chia bin: bin đều (mỗi bin rộng 0.1) và bin theo số lượng (mỗi bin chứa cùng số ca). Cách thứ hai ổn định hơn khi phần lớn xác suất dồn về gần 0 hoặc 1, khiến nhiều bin đều gần như trống. Với chỉ 66 ca test, mỗi bin có rất ít ca nên ECE khá nhiễu; đây là lý do cần khoảng tin cậy bootstrap.

AUROC

AUROC (diện tích dưới đường cong ROC) bằng xác suất một ca có u chọn ngẫu nhiên nhận điểm cao hơn một ca không u chọn ngẫu nhiên. AUROC = 0.5 là đoán mò, = 1 là tách hai nhóm hoàn hảo. AUROC đo khả năng phân biệt (xếp hạng), không đo hiệu chỉnh: một mô hình có thể xếp hạng rất tốt nhưng báo xác suất sai lệch, và ngược lại. Hai loại chỉ số vì thế bổ sung cho nhau.

Khoảng tin cậy bootstrap

Từ N ca thật, rút ngẫu nhiên có hoàn lại N ca (một ca có thể bị rút nhiều lần) để tạo một "tập dữ liệu giả", rồi tính lại chỉ số trên tập đó. Lặp lại 1000 lần, lấy phân vị 2.5% và 97.5% của 1000 giá trị, ta được khoảng tin cậy 95%. Khoảng rộng nghĩa là dữ liệu còn ít và kết luận chưa chắc chắn.

4 Hướng 1 — Per-Reader Adaptation

Khái niệm và Mục tiêu

Per-reader adaptation là việc học, từ chính các tương tác của một bác sĩ với AI, cách người đó *sử dụng* lời khuyên của AI (dễ tin hay hoài nghi, nhất quán hay không), rồi điều chỉnh chính sách hỗ trợ cho riêng người đó.

4.1 Động cơ

Nếu hành vi của bác sĩ A khác bác sĩ B thì chính sách hỗ trợ tối ưu cũng có thể khác: $\pi_A^* \neq \pi_B^*$. Repo *không* gán bác sĩ vào nhóm "nhiều/ít kinh nghiệm", vì Yu et al. [1] cho thấy những đặc điểm đó không dự báo được ai hưởng lợi. Thay vào đó, nó học trực tiếp từ các quyết định quan sát được. Quá trình cá nhân hóa lần lượt gồm: ghi nhận phản hồi, ước lượng trust curve, ước lượng lapse rate và tối ưu ngưỡng hỗ trợ. Các bước này được trình bày ở các mục 4.2–4.5.

4.2 Thu thập phản hồi theo giao thức đọc tuần tự

Mỗi lượt đọc là một `FeedbackEvent` (`readers/feedback.py`). Giao thức là **tuần tự**: bác sĩ ghi nhận định độc lập o_{ir} trước, sau đó mới xem gợi ý AI, rồi ra quyết định cuối f_{ir}. Trong giao diện, chế độ *blind first read* bắt buộc lưu nhận định trước khi AI được hiển thị.

```
{
  "reader_id":      "reader_a",
  "case_id":        "lits_042",
  "ai_probability": 0.86,
  "ai_confidence":  0.86,
  "uncertainty":    0.58,
  "initial_read":   0,
  "ai_label":       1,
  "shown":          True,
  "action":         "accept",
  "final_label":    1
}
```

Bác sĩ ban đầu cho rằng không có u, AI đề xuất có u với độ tin 0.86, và bác sĩ đổi sang "có u". Hệ thống quan sát được rằng bác sĩ đã nghe theo AI, nhưng chưa biết việc chuyển đó đúng hay sai nếu chưa đối chiếu nhãn tham chiếu.

Vì sao phải lưu riêng `initial_read`?

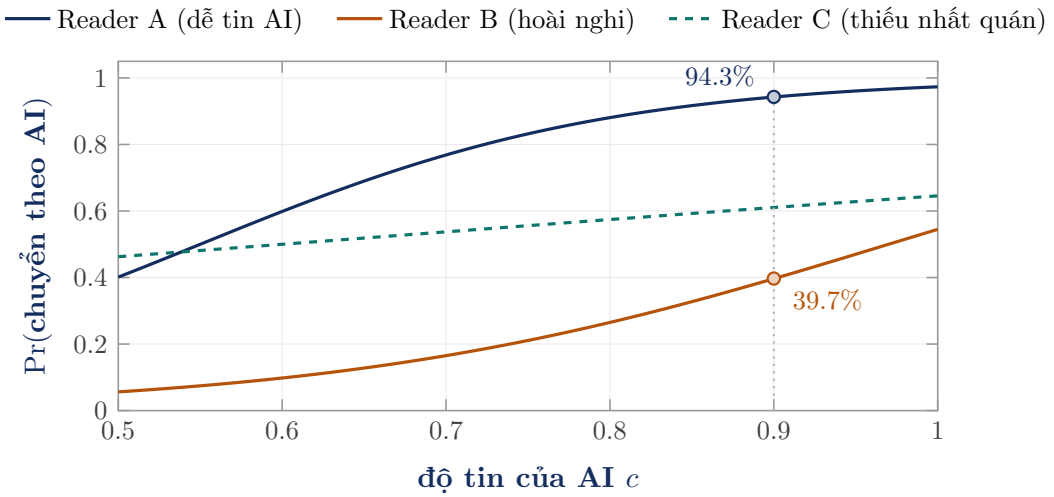
Nếu chỉ có quyết định cuối, ta không phân biệt được bác sĩ bị AI kéo theo hay vốn đã đồng ý từ trước. Lưu o_{ir} tách khỏi f_{ir} là điều kiện để đo automation bias, và như mục 5 cho thấy, cũng là điều kiện để đánh giá ngược (counterfactual) mọi chính sách trên cùng một log. Ngoài ra, tính đúng sai luôn được đánh giá theo mask tham chiếu, nên lỗi của bác sĩ không bao giờ trở thành nhãn đúng.

4.3 Mô hình Trust Curve và ước lượng logistic MAP

Câu hỏi: *khi bác sĩ và AI bất đồng, xác suất bác sĩ chuyển sang tin AI là bao nhiêu, theo độ tin của AI?* Repo mô hình hóa

$$\pi_r(c) = \sigma\big(\alpha_r + \beta_r\,(c - 0.75)\big), \qquad \sigma(z) = \frac{1}{1 + e^{-z}}, \tag{8}$$

trong đó c là độ tin của AI vào nhãn nó đề xuất, α_r là thiên hướng tin AI tại $c = 0.75$ (vì $\pi_r(0.75) = \sigma(\alpha_r)$; $\alpha_r = 0$ nghĩa là 50%), và β_r là độ nhạy của bác sĩ với độ tin của AI.



Hình 3: Trust curve của ba bác sĩ mô phỏng. Tại $c = 0.9$: Reader A chuyển theo AI với xác suất 94.3%, Reader B chỉ 39.7%.

Mục tiêu của ước lượng maximum a posteriori (MAP) là tìm hai con số $\boldsymbol{\theta}_r = (\alpha_r, \beta_r)$ sao cho đường cong $\pi_r(c)$ mô tả đúng nhất cách bác sĩ r đã hành xử. Quá trình ước lượng kết hợp dữ liệu quan sát được với một phân phối prior; từng thành phần được giải thích dưới đây.

4.3.1 Dữ liệu quan sát

Chỉ những lần bác sĩ bất đồng với AI mới cho biết họ có tin AI hay không. Với mỗi lần như vậy (đánh số j), ta ghi lại độ tin của AI c_j và kết quả z_j:

$$z_j = \begin{cases} 1 & \text{bác sĩ đổi sang ý của AI,} \\ 0 & \text{bác sĩ giữ ý ban đầu.} \end{cases}$$

4.3.2 Hàm likelihood

Nếu bác sĩ đổi theo AI ($z_j = 1$), đường cong tốt phải cho $\pi_r(c_j)$ cao; nếu bác sĩ giữ ý ($z_j = 0$), nó phải cho $1 - \pi_r(c_j)$ cao. Cộng log của các xác suất này qua mọi lần bất đồng:

$$\underbrace{\sum_j \Big[z_j \log \pi_r(c_j) + (1 - z_j) \log \big(1 - \pi_r(c_j)\big) \Big]}_{\text{càng lớn = càng khớp dữ liệu}} \tag{9}$$

Đây là đối số đối dấu của NLL ở mục 3.1; tối đa hóa tổng log-likelihood tương đương với tối thiểu hóa NLL. Nếu chưa đưa prior vào, cách ước lượng này gọi là maximum likelihood (ML).

4.3.3 Phân phối prior

MLE gặp vấn đề khi dữ liệu ít. Nếu bác sĩ mới bất đồng 3 lần và cả 3 lần đều đổi theo AI, MLE kết luận bác sĩ luôn luôn đổi theo AI ($\pi = 100\%$) và đẩy α ra vô cực. Repo vì vậy đặt trước một "đường cong mặc định" cùng mức độ tin vào nó, dưới dạng phân phối chuẩn:

$$\alpha_r \sim \mathcal{N}(0,\ 1.5^2), \qquad \beta_r \sim \mathcal{N}(4,\ 3^2).$$

Đọc là: trước khi có dữ liệu, ta đoán $\alpha \approx 0$ (khi AI tự tin 75%, bác sĩ đổi theo nửa số lần) và $\beta \approx 4$ (AI càng tự tin, bác sĩ càng dễ đổi theo). Độ lệch chuẩn (1.5 và 3) cho biết ta sẵn sàng rời các giá trị đoán này xa đến đâu khi dữ liệu đòi hỏi.

4.3.4 Ước lượng MAP

MAP tối đa hóa log-likelihood trừ đi một khoản phạt cho việc rời xa prior:

$$\begin{aligned} J(\alpha_r, \beta_r) = & \underbrace{\sum_j \Big[z_j \log \pi_r(c_j) + (1 - z_j) \log \big(1 - \pi_r(c_j)\big) \Big]}_{\text{log-likelihood}} \\ & - \underbrace{\left[\frac{\alpha_r^2}{2 \cdot 1.5^2} + \frac{(\beta_r - 4)^2}{2 \cdot 3^2} \right]}_{\text{mức phạt từ prior}}. \end{aligned} \tag{10}$$

Khi dữ liệu còn ít, khoản phạt chiếm ưu thế và kết quả gần prior. Khi dữ liệu nhiều, phần khớp dữ liệu áp đảo và kết quả gần MLE. Về bản chất, đây là hồi quy logistic có điều chuẩn, cùng ý tưởng với ridge ở bước hiệu chỉnh.

Dữ liệu của bác sĩ	$\hat{\alpha}$	$\hat{\beta}$	$\hat{\pi}(0.9)$ (AI tự tin 90%)
Chưa có lần bất đồng nào	0.00	4.00	0.646 (chỉ có prior)
3 lần, cả 3 đều đổi theo AI	1.03	4.62	0.848 (MLE sẽ nói 1.000)
30 lần, 27 lần đổi theo AI	1.29	4.77	0.881 (gần tỉ lệ thực 0.900)

4.4 Ước lượng tỉ lệ lapse

Trust curve chưa mô tả hết hành vi. Repo ước lượng thêm p_{lapse}: xác suất bác sĩ bỏ một kết luận vốn đã đồng ý với AI. Gọi n_r^{agree} là số ca nhận định ban đầu trùng với AI và k_r là số ca trong đó quyết định cuối lại khác. Với prior Beta$(1, 19)$ (trung bình 0.05), ước lượng hậu nghiệm là

$$\hat{p}_{\text{lapse},r} = \frac{k_r + 1}{n_r^{\text{agree}} + 20}. \tag{11}$$

Khi chưa có dữ liệu, $\hat{p}_{\text{lapse},r} = 1/20 = 0.05$. Cách làm trơn này tránh các ước lượng bằng 0 hoặc 1 chỉ vì có quá ít quan sát. Tuy nhiên đây vẫn là một phép đo còn đơn giản: nó không phân biệt bác sĩ đổi ý có lý do với bác sĩ đổi ý vì thiếu nhất quán.

4.5 Từ mô hình hành vi đến chính sách cá nhân hóa

Có $(\alpha_r, \beta_r, \hat{p}_{\text{lapse},r})$ rồi, `fit_policy()` dùng chúng để tính mất mát kỳ vọng của các chính sách khác nhau và chọn

$$\pi_r^* = (t_r^*,\, d_r^*). \tag{12}$$

Cách tối ưu cụ thể được trình bày ở mục 5, vì hai hướng gắn trực tiếp với nhau.

5 Hướng 2 — Learning to Defer

Khái niệm và Mục tiêu

Learning to defer [13, 14] là học, cho từng ca, có nên dựa vào đầu ra của AI hay nhường ca đó cho con người, sao cho mỗi ca đến tay bên có khả năng đúng cao hơn. Trong repo, "hoãn" (defer) nghĩa là **không hiển thị gợi ý AI và yêu cầu bác sĩ đọc độc lập**.

5.1 Khác gì so với đặt ngưỡng độ tin thông thường?

Một hệ thống AI thông thường chỉ quyết định nhãn: $\hat{y}_i = \mathbf{1}[p_i \geq 0.5]$. Nhưng việc hiển thị một gợi ý, kể cả khi xác suất cao, có thể kéo bác sĩ về phía sai (automation bias). Learning to defer thêm một quyết định thứ hai: có nên hiển thị gợi ý hay không? Mỗi ca

có hai lựa chọn: **SHOW** (hiển thị gợi ý để bác sĩ tham khảo) hoặc **DEFER** (giữ lại gợi ý, bác sĩ đọc độc lập). Về mặt lý thuyết, đây là dạng selective prediction [15]: hệ thống chọn những ca nó sẽ đưa ra dự đoán.

5.2 Quy tắc quyết định: AI làm gì với từng ca?

Với mỗi ca CT, hàm `ReaderPolicy.decide()` quyết định **có nên hiển thị gợi ý AI cho bác sĩ hay không và, nếu có, gợi ý nội dung gì**. Cơ chế này nhằm hạn chế automation bias: một dự đoán AI sai có thể khiến bác sĩ thay đổi nhận định theo hướng không chính xác [3].

Quy trình gồm ba bước: kiểm tra chất lượng, đánh giá độ bất định và xác định nhãn gợi ý. Khi hệ thống chọn **DEFER (hoãn)**, AI chỉ không hiển thị gợi ý; bác sĩ vẫn đọc ca CT độc lập như bình thường, không có việc AI tự kết luận hoặc chuyển ca cho người khác.

5.2.1 Kiểm tra chất lượng (QC)

Trước tiên, hệ thống thực hiện Quality Control (QC) để xác định kết quả phân tích có hợp lệ về mặt kỹ thuật hay không. Nếu không tìm thấy gan, thể tích gan hoặc voxel spacing bất thường, số lát cắt không đủ, hoặc vùng u dự đoán nằm bất hợp lý ngoài gan, hệ thống sẽ **DEFER** bất kể xác suất dự đoán.

5.2.2 Đánh giá độ bất định

Nếu QC đạt yêu cầu, hệ thống đánh giá mức độ không chắc chắn của AI thông qua hai đại lượng:

- u_i **(uncertainty):** độ bất định của AI đối với ca CT thứ i.
- d_r **(deferral threshold):** ngưỡng bất định mà chính sách của bác sĩ r cho phép.

Vì bài toán gồm hai khả năng "có u" và "không có u", repo tính độ bất định bằng **Binary Entropy**:

$$u_i = H(p_i) = -p_i \log_2(p_i) - (1 - p_i) \log_2(1 - p_i) \tag{13}$$

Entropy nằm trong khoảng $[0, 1]$ bit:

- Khi p_i gần 0 hoặc 1, AI nghiêng mạnh về một khả năng nên u_i thấp.
- Khi p_i gần 0.5, hai khả năng có xác suất tương đương nên u_i cao, đạt cực đại 1 bit tại $p_i = 0.5$.

Hệ thống so sánh độ bất định với ngưỡng hoãn:

- Nếu $u_i \geq d_r$: **DEFER**, không hiển thị gợi ý AI.
- Nếu $u_i < d_r$: **SHOW**, tiếp tục xác định nhãn và độ tin của gợi ý.

Ví dụ, với $d_r = 0.80$ và QC đạt yêu cầu:

- $p_i = 0.92$ cho $u_i \approx 0.40 < 0.80$: AI được phép SHOW.

- $p_i = 0.60$ cho $u_i \approx 0.97 \geq 0.80$: AI chọn DEFER.
- $p_i = 0.05$ cho $u_i \approx 0.29 < 0.80$: AI được phép SHOW.

Ngưỡng d_r có thể được cá nhân hóa theo từng bác sĩ. Ngưỡng thấp khiến AI im lặng ở nhiều ca hơn, trong khi ngưỡng cao cho phép hiển thị nhiều gợi ý hơn. Repo tối ưu ngưỡng này dựa trên feedback và expected loss, cân bằng giữa sai sót chẩn đoán và chi phí review.

Cần lưu ý rằng **entropy thấp không bảo đảm AI dự đoán đúng**: mô hình vẫn có thể sai dù đưa ra xác suất rất tự tin.

5.2.3 Xác định nhãn và độ tin của gợi ý

Nếu ca CT vượt qua hai bước kiểm tra trên, AI cần xác định **nhãn gợi ý** ("có u" hoặc "không có u") và **độ tin** tương ứng với nhãn đó.

Để chuyển xác suất p_i thành nhãn, hệ thống sử dụng **ngưỡng gợi ý** t_r (suggestion threshold) dành cho bác sĩ r:

- Nếu $p_i \geq t_r$: gợi ý **"có u"**, ký hiệu $a_i = 1$.
- Nếu $p_i < t_r$: gợi ý **"không có u"**, ký hiệu $a_i = 0$.

Ví dụ, xét một ca có xác suất "có u" là $p_i = 0.35$ và giả sử ca đủ điều kiện SHOW:

- Với $t_r = 0.50$, vì $0.35 < 0.50$, AI gợi ý "không có u".
- Với $t_r = 0.30$, vì $0.35 \geq 0.30$, AI gợi ý "có u".

Như vậy, **thay đổi t_r không làm thay đổi xác suất dự đoán p_i, mà chỉ thay đổi nhãn được chọn**. Ngưỡng thấp hơn khiến AI dễ cảnh báo "có u" hơn, có thể giảm bỏ sót nhưng đồng thời tăng nguy cơ báo động giả.

Sau khi chọn nhãn, hệ thống tính c_i **(confidence)**, tức xác suất AI gán cho chính nhãn đó:

- Nếu gợi ý "có u", $c_i = p_i$.
- Nếu gợi ý "không có u", $c_i = 1 - p_i$.

Với ví dụ $p_i = 0.35$, nếu $t_r = 0.50$ thì AI gợi ý "không có u" với $c_i = 0.65$; nếu $t_r = 0.30$ thì AI gợi ý "có u" với $c_i = 0.35$. Do đó, khi threshold được cá nhân hóa, c_i không nhất thiết lớn hơn 0.50.

5.2.4 Tổng hợp quy tắc quyết định

Ký hiệu $\mathbf{1}[\cdot]$ trả về 1 nếu điều kiện đúng và 0 nếu sai; $\neg$ nghĩa là "không", còn $\vee$ nghĩa là "hoặc". Toàn bộ quy trình được biểu diễn bằng ba công thức:

$$D_i = \mathbf{1}\big[\neg \mathrm{QC}_i \vee u_i \geq d_r\big], \qquad \text{quyết định hoãn: } 1 = \text{DEFER},\ 0 = \text{SHOW}, \tag{14}$$

$$a_i(t_r) = \mathbf{1}[p_i \geq t_r], \qquad \text{nhãn gợi ý: } 1 = \text{có u},\ 0 = \text{không có u}, \tag{15}$$

$$c_i = \begin{cases} p_i, & a_i = 1, \\ 1 - p_i, & a_i = 0, \end{cases} \qquad \text{xác suất gán cho nhãn được gợi ý.} \tag{16}$$

Theo đó, hàm `ReaderPolicy.decide()` đưa ra quyết định cuối cùng:

$$\mathrm{Decision}(i, r) = \begin{cases} \text{DEFER} & \text{nếu QC thất bại,} \\ \text{DEFER} & \text{nếu } u_i \geq d_r, \\ \text{SHOW: } a_i(t_r) \text{ cùng } c_i & \text{trong các trường hợp còn lại.} \end{cases} \tag{17}$$

5.3 Tối ưu ngưỡng cá nhân hóa bằng mất mát kỳ vọng

Sau khi xác định quy tắc SHOW/DEFER ở mục 5.2, câu hỏi tiếp theo là: **làm thế nào để chọn ngưỡng gợi ý t_r và ngưỡng hoãn d_r phù hợp với từng bác sĩ?**

Repo sử dụng phương pháp **tối thiểu hóa mất mát kỳ vọng** (expected-loss minimization). Ý tưởng là thử các cặp ngưỡng (t, d) trên những ca đã có phản hồi và nhãn tham chiếu, ước tính sai sót cùng công sức của bác sĩ trong từng trường hợp, rồi chọn cặp có tổng mất mát thấp nhất.

Để thực hiện, hệ thống cần xác định hai loại chi phí và dự đoán hành vi của bác sĩ khi AI hiển thị hoặc không hiển thị gợi ý.

5.3.1 Định nghĩa hàm mất mát

Gọi y là kết luận cuối cùng của bác sĩ và g là nhãn tham chiếu (1: có u, 0: không có u). Ta quy định:

Kết quả	y	g	Điểm phạt $\ell(y, g)$
Phát hiện đúng khối u	1	1	0
Phát hiện đúng không có u	0	0	0
Bỏ sót u (False Negative)	0	1	2
Báo động giả (False Positive)	1	0	1

Như vậy, hàm mất mát chẩn đoán là:

$$\ell(y, g) = w_{\mathrm{FN}}\mathbf{1}[y = 0, g = 1] + w_{\mathrm{FP}}\mathbf{1}[y = 1, g = 0], \qquad w_{\mathrm{FN}} = 2, \quad w_{\mathrm{FP}} = 1. \tag{18}$$

Bỏ sót u bị phạt gấp đôi báo động giả. Đây là trọng số được lựa chọn trong prototype,

chưa phải tỷ lệ chi phí lâm sàng đã được kiểm chứng.

Chi phí về công sức: Ngoài độ chính xác, repo còn gán chi phí quy ước cho các hành động của bác sĩ:

Hành động	Chấp nhận AI	Bác bỏ AI	Sửa AI	Đọc độc lập
Chi phí C	1	2	3	4

Chi phí này được nhân với hệ số $\lambda = 0.02$, nhằm ưu tiên giảm lỗi chẩn đoán nhưng vẫn xét đến công sức. Chẳng hạn, đọc độc lập có chi phí $0.02 \times 4 = 0.08$, nhỏ hơn nhiều so với một lỗi chẩn đoán. Chi phí sửa kết quả ($C_{\text{edit}} = 3$) có trong cấu hình nhưng chưa được mô hình hóa riêng trong công thức tối ưu policy.

5.3.2 Mất mát kỳ vọng khi SHOW

Khi AI đưa ra gợi ý, bác sĩ có thể **giữ nhãn AI hoặc bác bỏ nhãn đó**. Để ước tính khả năng xảy ra mỗi kết quả, repo sử dụng nhận định ban đầu o_{ir} của bác sĩ và mô hình hành vi đã học ở mục 4.3.

Gọi a_i là nhãn AI gợi ý và c_i là xác suất gán cho nhãn đó. Có hai tình huống:

- **Nếu bác sĩ và AI đồng ý** ($o_{ir} = a_i$): bác sĩ thường giữ nguyên nhãn, ngoại trừ khả năng thay đổi quyết định được mô hình hóa bởi *lapse rate* $\hat{p}_{\text{lapse},r}$.
- **Nếu bác sĩ và AI bất đồng** ($o_{ir} \neq a_i$): xác suất bác sĩ chuyển sang nhãn AI được ước lượng bằng *trust curve* $\pi_r(c_i)$.

Do đó, xác suất bác sĩ cuối cùng giữ nhãn AI, ký hiệu q_{ir}, được tính như sau:

$$q_{ir} = \begin{cases} 1 - \hat{p}_{\text{lapse},r}, & o_{ir} = a_i, \\ \pi_r(c_i), & o_{ir} \neq a_i. \end{cases} \tag{19}$$

Nói cách khác, với xác suất q_{ir}, bác sĩ chọn nhãn AI a_i; với xác suất $1 - q_{ir}$, bác sĩ chọn nhãn ngược lại $1 - a_i$.

Vì chưa biết trước bác sĩ sẽ lựa chọn cách nào, hệ thống tính **mất mát kỳ vọng** bằng trung bình có trọng số của hai kết quả, cộng chi phí công sức tương ứng:

$$\begin{aligned} L_i^{\text{show}} = & \underbrace{q_{ir}\ell(a_i, g_i) + (1 - q_{ir})\ell(1 - a_i, g_i)}_{\text{Mất mát chẩn đoán kỳ vọng}} \\ & + \underbrace{\lambda\left[q_{ir}C_{\text{accept}} + (1 - q_{ir})C_{\text{reject}}\right]}_{\text{Chi phí công sức kỳ vọng}}. \end{aligned} \tag{20}$$

Ví dụ, nếu $q_{ir} = 0.8$, hệ thống giả định bác sĩ có 80% khả năng giữ nhãn AI và 20% khả năng chọn nhãn ngược lại. Mỗi kết quả được tính điểm phạt dựa trên nhãn tham chiếu g_i, rồi cộng theo các xác suất tương ứng.

5.3.3 Mất mát khi DEFER

Khi AI im lặng, bác sĩ tiếp tục dựa trên nhận định độc lập o_{ir}, không chịu ảnh hưởng của gợi ý AI. Trong mô hình tối ưu của repo, kết luận cuối cùng được giả định bằng nhận định ban đầu đó.

Mất mát khi hoãn vì vậy được tính trực tiếp:

$$L_i^{\text{defer}} = \ell(o_{ir}, g_i) + \lambda C_{\text{manual}}. \tag{21}$$

So với SHOW, DEFER có hai mặt:

- **Lợi ích:** tránh nguy cơ bác sĩ bị một gợi ý AI sai làm thay đổi kết luận đúng.
- **Đánh đổi:** bỏ lỡ cơ hội AI sửa một nhận định sai của bác sĩ, đồng thời tăng chi phí đọc độc lập.

Do đó, **không phải lúc nào hoãn nhiều hơn cũng tốt hơn**. Chính sách phù hợp cần cân bằng lợi ích chẩn đoán và công sức của bác sĩ.

5.3.4 Tối ưu cặp ngưỡng

Với mỗi cặp ngưỡng được thử, hệ thống áp dụng quy tắc ở mục 5.2 để xác định:

- $D_i = 1$: ca được DEFER, sử dụng L_i^{defer}.
- $D_i = 0$: ca được SHOW, sử dụng L_i^{show}.

Mất mát trung bình trên N ca có phản hồi và nhãn tham chiếu của bác sĩ r là:

$$\bar{L}_r(t, d) = \frac{1}{N} \sum_{i=1}^{N} \left[D_i L_i^{\text{defer}} + (1 - D_i) L_i^{\text{show}} \right]. \tag{22}$$

Repo thử nhiều cặp (t, d) bằng *grid search* và chọn chính sách có mất mát kỳ vọng thấp nhất, đồng thời sử dụng regularization và các điều kiện kiểm tra mức cải thiện trước khi chấp nhận cá nhân hóa.

Điểm quan trọng là L_i^{show} phụ thuộc vào q_{ir}, mà q_{ir} được ước lượng từ **trust curve và lapse rate riêng của từng bác sĩ**. Vì vậy, cùng một ca CT có thể dẫn đến những chính sách hỗ trợ khác nhau giữa các bác sĩ.

Chẳng hạn, một bác sĩ thường xuyên tin theo AI có thể chịu rủi ro lớn hơn khi AI đưa ra gợi ý sai. Ngược lại, một bác sĩ ít bị ảnh hưởng bởi AI có thể có mức rủi ro khác. Tuy nhiên, ngưỡng tối ưu không được quyết định chỉ từ mức độ tin AI, mà từ tổng mất mát dự kiến trên các ca đã quan sát.

Vì sao có thể đánh giá nhiều chính sách mà không cần bác sĩ đọc lại từng ca?

Repo ghi nhận **nhận định ban đầu o_{ir} trước khi bác sĩ xem AI**. Nhờ đó, trên những ca đã có nhãn tham chiếu g_i, hệ thống có thể thử một cặp ngưỡng (t, d) khác, tính lại nhãn gợi ý a_i, confidence c_i và quyết định SHOW/DEFER, rồi sử dụng mô hình hành vi của bác sĩ để ước tính kết quả cuối cùng.

Đây là một dạng model-based counterfactual policy evaluation: ước tính điều gì có thể xảy ra nếu sử dụng một chính sách khác, thay vì yêu cầu bác sĩ thực sự đọc lại toàn bộ ca.

Giới hạn: các kết quả này phụ thuộc vào độ chính xác của trust curve và lapse model, cũng như giả định rằng nhận định độc lập của bác sĩ không thay đổi khi chính sách hỗ trợ thay đổi. Vì vậy, mất mát kỳ vọng là một ước lượng dựa trên mô hình, không phải hiệu quả lâm sàng đã được quan sát trực tiếp.

6 Hướng 3 — Human–AI Evaluation

Khái niệm và Mục tiêu

Human–AI evaluation không hỏi riêng "AI chính xác đến đâu?", mà hỏi **"quyết định cuối cùng của bác sĩ thay đổi thế nào khi có AI hỗ trợ?"** Vì vậy, đơn vị đánh giá chính trong phần này là quyết định cuối f_{ir} của bác sĩ r trên ca i, sau khi áp dụng quy tắc SHOW/DEFER ở mục 5.2 và chính sách được học từ mất mát kỳ vọng ở mục 5.3.

Mục tiêu của thí nghiệm là kiểm tra ba câu hỏi: AI có giúp bác sĩ đọc chính xác hơn không; cá nhân hóa có giúp các bác sĩ hưởng lợi đồng đều hơn không; và cơ chế DEFER có giảm tác hại khi AI đưa ra gợi ý sai không. Repo hiện trả lời các câu hỏi này bằng **bác sĩ mô phỏng**; do đó kết quả là bằng chứng trong môi trường mô phỏng, không phải bằng chứng về hiệu quả lâm sàng.

6.1 Bác sĩ mô phỏng

Một nghiên cứu reader study thực tế cần nhiều bác sĩ đọc cùng một tập ca dưới nhiều chính sách khác nhau, điều khó thực hiện ở giai đoạn phát triển ban đầu. Vì vậy, `radagent/readers/profiles.py` định nghĩa ba **reader profile tham số**. Đây không phải LLM đóng vai bác sĩ, mà là mô hình xác suất được lập trình để tạo ra những kiểu hành vi khác nhau: dễ tin AI, hoài nghi AI và thiếu nhất quán.

6.1.1 Nhận định độc lập trước khi xem AI

Trước khi thấy AI, bác sĩ tạo nhận định ban đầu o_{ir}. Nếu ca thật sự có u ($g_i = 1$), xác suất bác sĩ gọi "có u" phụ thuộc vào thể tích tổn thương V_i và độ tương phản $\Delta\mathrm{HU}_i$:

$$\Pr(o_{ir} = 1 \mid g_i = 1) = \sigma\left(a_r + b_r \log_{10}\max(V_i, 0.01) + c_r \frac{|\Delta\mathrm{HU}_i| - 20}{10}\right), \tag{23}$$

còn nếu không có u:

$$\Pr(o_{ir} = 1 \mid g_i = 0) = \mathrm{FPR}_r. \tag{24}$$

Nhờ đó, tổn thương lớn và rõ thường dễ được phát hiện hơn tổn thương nhỏ hoặc mờ. Các đặc trưng V_i và $\Delta\mathrm{HU}_i$ được lấy từ ca và nhãn tham chiếu để điều khiển độ khó của mô phỏng.

6.1.2 Phản ứng sau khi nhận gợi ý AI

Nếu chính sách ở mục 5.2 chọn SHOW, AI đưa ra nhãn a_i với confidence c_i. Hành vi của bác sĩ được mô phỏng như sau:

$$\Pr(\text{chuyển theo AI} \mid o_{ir} \neq a_i) = \sigma(k_r(c_i - \tau_r)). \tag{25}$$

Nếu $o_{ir} = a_i$, bác sĩ giữ nguyên nhãn đó. Nếu hai bên bất đồng, bác sĩ chuyển theo gợi ý AI với xác suất được xác định bởi trust curve ở trên. Ngoài ra, với xác suất lapse_r, quyết định cuối cùng được thay bằng một lựa chọn ngẫu nhiên, nhằm mô phỏng sự thiếu nhất quán.

Nếu bác sĩ giữ một gợi ý dương tính của AI nhưng đường viền khối u kém chất lượng, hành động có thể được ghi nhận là `edit`. Tham số `edit_noise` mô phỏng những lần sửa không cần thiết. Ở đây, `edit` chỉ biểu thị một hành động trong mô hình hành vi, không phải thao tác chỉnh sửa từng voxel.

Ba hồ sơ bác sĩ mô phỏng được thiết kế để thể hiện những cách tương tác khác nhau với AI:

	Reader A	Reader B	Reader C
Kiểu hành vi	dễ phụ thuộc AI	hoài nghi	thiếu nhất quán
$\mathrm{trust}_k/\mathrm{trust}_\tau$	8.0/0.55	6.0/0.97	1.5/0.60
lapse	0.02	0.02	0.15
FPR	0.12	0.04	0.15
(a_r, b_r, c_r)	$(0.8, 1.5, 0.8)$	$(0.9, 1.8, 0.8)$	$(0.7, 1.0, 0.6)$
$\mathrm{edit}_{poor}/\mathrm{edit}_{noise}$	0.20/0.02	0.80/0.15	0.50/0.30

Bảng 3: Ba hồ sơ bác sĩ mô phỏng mặc định trong `radagent/config.py`.

6.2 Các chính sách được so sánh

Phần đánh giá tập trung vào bốn nhánh cần thiết để trả lời trực tiếp câu hỏi "AI có giúp không?", "cá nhân hóa có giúp không?" và "DEFER có thêm giá trị không?":

Chính sách	Ngưỡng gợi ý	Cơ chế DEFER
`no_ai`	không dùng AI	bác sĩ đọc độc lập
`universal`	$t = 0.5$ cho mọi bác sĩ	chỉ DEFER khi QC thất bại
`reader_threshold`	t_r riêng từng bác sĩ	chỉ DEFER khi QC thất bại
`reader_threshold_defer`	t_r riêng từng bác sĩ	dùng thêm d_r riêng từng bác sĩ

Bảng 4: Bốn nhánh chính dùng để đánh giá tác động của AI, cá nhân hóa và learning to defer.

Các so sánh có ý nghĩa trực tiếp:

- `no_ai` vs. `universal`: AI hỗ trợ nói chung có cải thiện quyết định của bác sĩ hay không;
- `universal` vs. `reader_threshold`: cá nhân hóa ngưỡng gợi ý có thêm lợi ích hay không;
- `reader_threshold` vs. `reader_threshold_defer`: cá nhân hóa thêm quyết định SHOW/DEFER có giảm rủi ro hay không.

6.3 Các chỉ số đánh giá

Gọi f_{ir} là quyết định cuối của bác sĩ, g_i là nhãn tham chiếu, a_i là nhãn AI được hiển thị và N là số ca test. Các chỉ số chính đều được tính từ **quyết định cuối của bác sĩ**, không phải chỉ từ dự đoán của AI.

6.3.1 Độ chính xác và lỗi có trọng số

$$\text{Accuracy}_r = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}[f_{ir} = g_i], \tag{26}$$

$$\text{WeightedError}_r = \frac{1}{N}\sum_{i=1}^{N} \left(w_{\text{FN}}\mathbf{1}[f_{ir} = 0, g_i = 1] + w_{\text{FP}}\mathbf{1}[f_{ir} = 1, g_i = 0]\right). \tag{27}$$

Weighted error sử dụng cùng w_{FN} và w_{FP} như hàm mất mát ở mục 5.3, nhờ đó tiêu chí tối ưu và tiêu chí đánh giá giữ cùng cách coi trọng lỗi bỏ sót và báo động giả.

6.3.2 Tác hại khi AI đưa ra gợi ý sai

Ta đặt

$$\mathcal{W} = \{i : \text{AI được SHOW và } a_i \neq g_i\},$$

là tập các ca AI sai đã thực sự được hiển thị cho bác sĩ. Khi đó:

$$\text{HAR} = \frac{\#\{i \in \mathcal{W} : f_{ir} = a_i\}}{N}, \tag{28}$$

$$\text{OverReliance} = \frac{\#\{i \in \mathcal{W} : f_{ir} = a_i\}}{|\mathcal{W}|}. \tag{29}$$

HAR (harmful acceptance rate) cho biết bao nhiêu phần của toàn bộ ca test kết thúc bằng việc bác sĩ làm theo một gợi ý AI sai. Trong khi đó, **OverReliance** chỉ xét những ca AI sai đã được hiển thị và hỏi bác sĩ đã đi theo AI trong bao nhiêu phần số ca đó.

6.3.3 Tỷ lệ DEFER

$$\text{DeferralRate} = \frac{\#\{\text{ca không hiển thị gợi ý AI}\}}{N}. \tag{30}$$

Chỉ số này cần được đọc cùng accuracy và HAR. Deferral rate thấp không tự động tốt, vì hiển thị quá nhiều có thể làm tăng harmful acceptance; ngược lại, defer quá nhiều có thể bỏ lỡ những ca AI giúp sửa nhận định sai của bác sĩ.

6.3.4 Lợi ích theo từng bác sĩ

Để đo AI giúp mỗi bác sĩ bao nhiêu so với đọc độc lập, với chính sách k định nghĩa:

$$B_{r,k} = \text{Accuracy}_{r,k} - \text{Accuracy}_{r,\text{no_ai}}. \tag{31}$$

Giá trị $B_{r,k} > 0$ nghĩa là bác sĩ r chính xác hơn khi dùng chính sách k so với khi đọc một mình; $B_{r,k} < 0$ nghĩa là AI làm kết quả của bác sĩ kém đi.

Độ không đồng đều của lợi ích giữa các bác sĩ được tóm tắt bằng:

$$\text{Spread}_k = \max_r \overline{B}_{r,k} - \min_r \overline{B}_{r,k}, \tag{32}$$

trong đó $\overline{B}_{r,k}$ là lợi ích trung bình của bác sĩ r qua các seed.

6.4 Ý nghĩa và giới hạn của kết quả mô phỏng

Thiết kế trên cho phép so sánh các chính sách trong một môi trường được kiểm soát: cùng ca test, cùng reader profile và cùng random draws. Nó phù hợp để kiểm tra logic của pipeline, đo learning curve và phát hiện những chính sách có nguy cơ làm tăng over-reliance trước khi tổ chức reader study thật.

Tuy nhiên, kết quả phải được hiểu là **ước lượng dựa trên mô hình hành vi**. Ba reader profile hiện được xác định bằng tham số cấu hình, chưa được fit từ dữ liệu hành vi của bác sĩ thật. Hơn nữa, simulator và mô hình policy đều sử dụng những dạng hành vi tương đối đơn giản, chẳng hạn trust phụ thuộc chủ yếu vào confidence của AI. Vì vậy,

một chính sách hoạt động tốt trong mô phỏng chưa chứng minh rằng nó sẽ tạo ra cùng mức lợi ích khi triển khai với radiologist thật.

Do đó, Human–AI Evaluation trong repo nên được xem là bước đánh giá tiền lâm sàng của chính sách: nó kiểm tra liệu chuỗi

$$\text{feedback} \longrightarrow \text{mô hình hành vi} \longrightarrow (t_r, d_r) \longrightarrow \text{SHOW/DEFER} \longrightarrow f_{ir}$$

có tạo ra lợi ích trong môi trường mô phỏng hay không. Kết luận cuối cùng về automation bias, lợi ích cá nhân hóa, gánh nặng đọc và độ an toàn vẫn cần được xác nhận bằng reader study hoặc pilot với bác sĩ thật trên dữ liệu độc lập.

Tài liệu

[1] F. Yu, A. Moehring, O. Banerjee, et al. Heterogeneity and predictors of the effects of AI assistance on radiologists. *Nature Medicine*, 30:837–849, 2024.

[2] N. Agarwal, A. Moehring, P. Rajpurkar, T. Salz. Combining human expertise with artificial intelligence: experimental evidence from radiology. *NBER Working Paper* 31422, 2023.

[3] T. Dratsch, X. Chen, M. Rezazade Mehrizi, et al. Automation bias in mammography: the impact of artificial intelligence BI-RADS suggestions on reader performance. *Radiology*, 307(4), 2023.

[4] D. Prinster, A. Mahmood, S. Saria, et al. Care to explain? AI explanation types differentially impact chest radiograph diagnostic performance and physician trust in AI. *Radiology*, 2024.

[5] K. Dvijotham, J. Winkens, M. Barsbey, et al. Enhancing the reliability and accuracy of AI-enabled diagnosis via complementarity-driven deferral to clinicians. *Nature Medicine*, 29:1814–1820, 2023.

[6] R. Tanno, D. G. T. Barrett, A. Sellergren, et al. Collaboration between clinicians and vision–language models in radiology report generation. *Nature Medicine*, 2025.

[7] A. Fallahpour, J. Ma, A. Munim, H. Lyu, B. Wang. MedRAX: Medical reasoning agent for chest X-ray. *ICML*, 2025.

[8] Y. He, P. Guo, Y. Tang, et al. VISTA3D: A unified segmentation foundation model for 3D medical imaging. *CVPR*, 2025.

[9] P. Bilic, P. Christ, H. B. Li, et al. The Liver Tumor Segmentation Benchmark (LiTS). *Medical Image Analysis*, 84:102680, 2023.

[10] C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger. On calibration of modern neural networks. *ICML*, 2017.

[11] J. Platt. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. *Advances in Large Margin Classifiers*, 1999.

[12] S. Depeweg, J. M. Hernández-Lobato, F. Doshi-Velez, S. Udluft. Decomposition of uncertainty in Bayesian deep learning for efficient and risk-sensitive learning. *ICML*, 2018.

[13] D. Madras, T. Pitassi, R. Zemel. Predict responsibly: improving fairness and accuracy by learning to defer. *NeurIPS*, 2018.

[14] H. Mozannar, D. Sontag. Consistent estimators for learning to defer to an expert. *ICML*, 2020.

[15] Y. Geifman, R. El-Yaniv. Selective classification for deep neural networks. *NeurIPS*, 2017.

[16] AIVIETNAM-AIO-khaisiubeo. *Radiologist-Centered AI Agent* (mã nguồn). https://github.com/AIVIETNAM-AIO-khaisiubeo/Radiologist-Centered-AI-Agent.